# 陕西省黄河流域水质分析评价及预测模型

## 摘要

在国家大力推进生态环境保护与科技创新的背景下，本研究积极响应政策号召，聚焦陕西省全境黄河流域开展水质分析、评价与预测工作。2025 年，生态环境部等多部门联合发布《关于加强生态环境领域科技创新 推动美丽中国建设的实施意见》，明确提出加强生态环境相关研究、探索新理论等要求；此前，习近平总书记也在全国生态环境保护大会上强调加快建立现代化生态环境监测体系。本研究紧密围绕这些政策导向，旨在为生态环境保护贡献力量。

研究收集了 2021 年 1 月至 2025 年 4 月的水质数据与 GIS 数据，综合运用 M-K 趋势检验、层次聚类分析、新型综合水质指数法（WQI-DET）、主成分分析以及机器学习方法（SHAP 分析法、Extra Trees）进行深入探究。研究结果显示，该流域部分水质指标变化较为稳定，而氨氮、总磷、总氮和 WQI-DET 等指标呈现明显下降趋势且存在周期性变化；通过聚类分析发现水质在空间上可分为近黄河干流类和近渭河干流类，在时间上可按季节划分为不同类别；主成分分析成功筛选出不同区域和时段的主要污染因子；在水质预测模型构建方面，确定 ExtraTreesRegressor 模型在 WQI-DET 计算和预测模型中表现最佳。这一系列研究成果表明黄河水治理形势依然严峻，但也体现出治理工作已取得一定成效，同时明确了不同区域的污染特征。

本研究的创新点在于重点关注陕西省内黄河流域水质的时空变化，尤其是对各支流进行了深入研究；利用 Python 库简化神经网络模型的选取与计算过程，并引入 SHAP 分析、泰勒图等前沿方法，为神经网络在水质分析领域的应用开辟了新路径，也为后续研究和水质治理提供了重要参考。

**关键词：**黄河流域 水质分析 WQI-DET 机器学习 时空变化

# 目录


摘要.....II

目录.....III

表格与插图清单.....V

一、引言.....1

（一）研究背景与意义.....1

1.研究背景.....1

2.研究意义.....2

①理论意义.....2

②实践意义.....2

（二）研究思路与创新.....2

1.研究创新.....2

2.研究思路.....3

二、材料与方法.....4

（一）研究区域及数据来源.....4

1.研究区域.....4

2.研究数据.....5

（二）研究方法.....6

1.M-K 趋势检验.....6

2.层次聚类分析.....7

3. 新型综合水质指数法(WQI-DET).....9

4. 主成分分析.....10

5.机器学习方法.....11

①SHAP 分析法.....11

②Extra Trees（极端随机森林）.....11

三、结果与讨论.....13

（一） 数据整体性处理及分析.....13

1. 正态性检验.....13

2. 斯皮尔曼相关系数.....13

3.M-K 趋势检验.....14
4.层次聚类分析.....17
(二)数据区域性处理及分析.....18
1.各指标分析.....18
2.主成分分析.....19
(三)水质预测模型构建.....20
1. WQI-DET 计算模型.....20
2. WQI-DET 预测模型.....22
四、结论.....24
参考文献.....25
致谢.....27

# 表格与插图清单

图 1 研究思路图.....3
图 2 研究区域图.....4
图 3 各变量 M-K 趋势图.....16
图 4 时间层次聚类分析图.....17
图 5 空间层次聚类分析图.....17
图 6 汛期 M-K 检验结果图.....18
图 7 非汛期 M-K 检验结果图.....19
图 8 WQI-DET 计算模型泰勒图.....21
图 9 SHAP 分析图.....21
图 10 WQI-DET 预测模型泰勒图.....22
图 11 预测 WQI-DET 汛期 M-K 检验结果图.....23

表 1 水质等级表.....10
表 2 斯皮尔曼相关系数表.....13
表 3 主成分分析结果表.....20

# 一、引言

## （一）研究背景与意义

### 1.研究背景

2025 年 2 月 13 日，为全面贯彻党的二十大和二十届二中、三中全会精神，深入贯彻落实全国生态环境保护大会和全国科技大会要求，进一步推动《中共中央 国务院关于全面推进美丽中国建设的意见》落实落地，生态环境部、国家发展改革委、教育部、工业和信息化部、财政部、人力资源社会保障部、自然资源部、住房城乡建设部、交通运输部、水利部、农业农村部、国务院国资委、中国科学院、中国气象局、国家林草局、国家自然科学基金委共同研究制定了《关于加强生态环境领域科技创新 推动美丽中国建设的实施意见》（以下简称《意见》）。《意见》中明确指出，要“加强生态环境健康、基准和标准研究”，“探索适用自然资源和生态环境时空表达、分析、建模的新理论”[1]。在此之前，习近平总书记在全国生态环境保护大会上指出要“加快建立现代化生态环境监测体系”，明确了做好新时期生态环境监测工作的总纲领、总方针、总遵循。结合 2025 年 1 月 12 日，生态环境部发布的《关于建设美丽中国先行区的实施意见》中，“推动黄河流域上中下游协同保护和治理[2]。”的要求和陕西省自然生态环境特点，紧扣本届大赛“统计创新应用、数据引领未来”的主题，我们开展关于陕西省全境黄河流域水质分析、评价与预测的研究。

水质评价是使用特定方法定量描述水质状况的分析手段[6]，主要方法包括单因子评价法、污染指数评价法[7]、模糊数学评价法[8]和人工神经网络评价法[9]等。上述评价方法都有其各自的优缺点。例如，单因子指数评价过程操作简单，但评价结果决定于最差指标，难以反映水体总体情况；污染指数法评价过程中结果与研究人员所取权重标准相关性过高，而权重的确定又很容易带有强烈的主观性[10]；模糊数学以及人工神经网络计算过程比较复杂，应用难度高。徐祖信[3]的研究提出了综合水质标识指数(WQI)，对水质进行了综合评价，打破传统水质评价中指标单一、主观性强的局限，以简洁高效的方式反映流域整体水质状况。相比其他方法更适用于对流域整体范围进行长期水质评价[4]。WQI 及 WQI 的改进方法在水环境质量评价中得到了广泛应用:；Huang 等[5]提出了新型综合水质指数(WQI-DET)并对中国湖泊水质状况进行分析评价。本文采用 WQI-DET 和人工神经网络评价

法，利用 WQI-DET 对现有水质数据进行综合评估，并基于神经网络分析 WQI-DET 的计算和预测未来水质走向，力求为今后的水质分析、评价与预测提供参考。

**2.研究意义**

①理论意义

本研究聚焦陕西省境内黄河流域，积极响应习近平总书记及国家生态环保号召。通过深入剖析该流域近年来的水质状况并预测未来趋势，丰富了陕西本土水文与环境监测的理论成果，完善了本地水文变化规律及环境监测指标体系相关理论，为后续研究提供了详实的理论依据与研究思路，助力构建现代化生态环境监测体系，推动污染防治工作。

②实践意义

研究全面统计和精准分析了陕西省黄河流域近年的水质数据，既关注当下水质状况，又着眼未来发展。通过科学预测，为黄河水质监测工作提供实用建议，助力改善水质，保障黄河流域生态环境。同时，验证了人工智能算法在环境预测中的可行性，推动水质数据预测向数智化转型，为环境监测与保护的高效化、智能化发展奠定实践基础，开拓了黄河流域水质保护的新路径。

## （二）研究思路与创新

**1.研究创新**

在研究内容上，现有黄河水质研究存在明显不足。大量研究以黄河干流整体为对象，针对陕西省内黄河流域，尤其是其众多支流的水质时空变化专项研究极少。这导致难以全面了解该区域水环境状况，无法为精准治理提供有力支持。并且，多数河流水质研究仅对现有数据进行静态分析，而预测污染量未来走势对提前制定水质保护策略、预防水质恶化意义重大，却未得到足够重视。本文对陕西省黄河流域所有断面分别进行了整体和区域性分析，力求弥补这一空白。

在研究方法上，本研究在传统环境数据处理分析基础上进行创新。传统观念认为神经网络用于水质分析效果好，但模型选取和计算复杂。本文利用 Lazy predict 库等工具简化了这一过程，还对多种神经网络模型进行对比，为后续研究的模型选择提供参考。此外，引入 SHAP 分析和泰勒图等前沿方法，前者可剖析模型预测的影响因素，助于理解模型决策；后者能直观展示模型预测与实际观测的差异，评估模型性能，为神经网络在水质分析领域的应用开拓了新方向。

2.研究思路

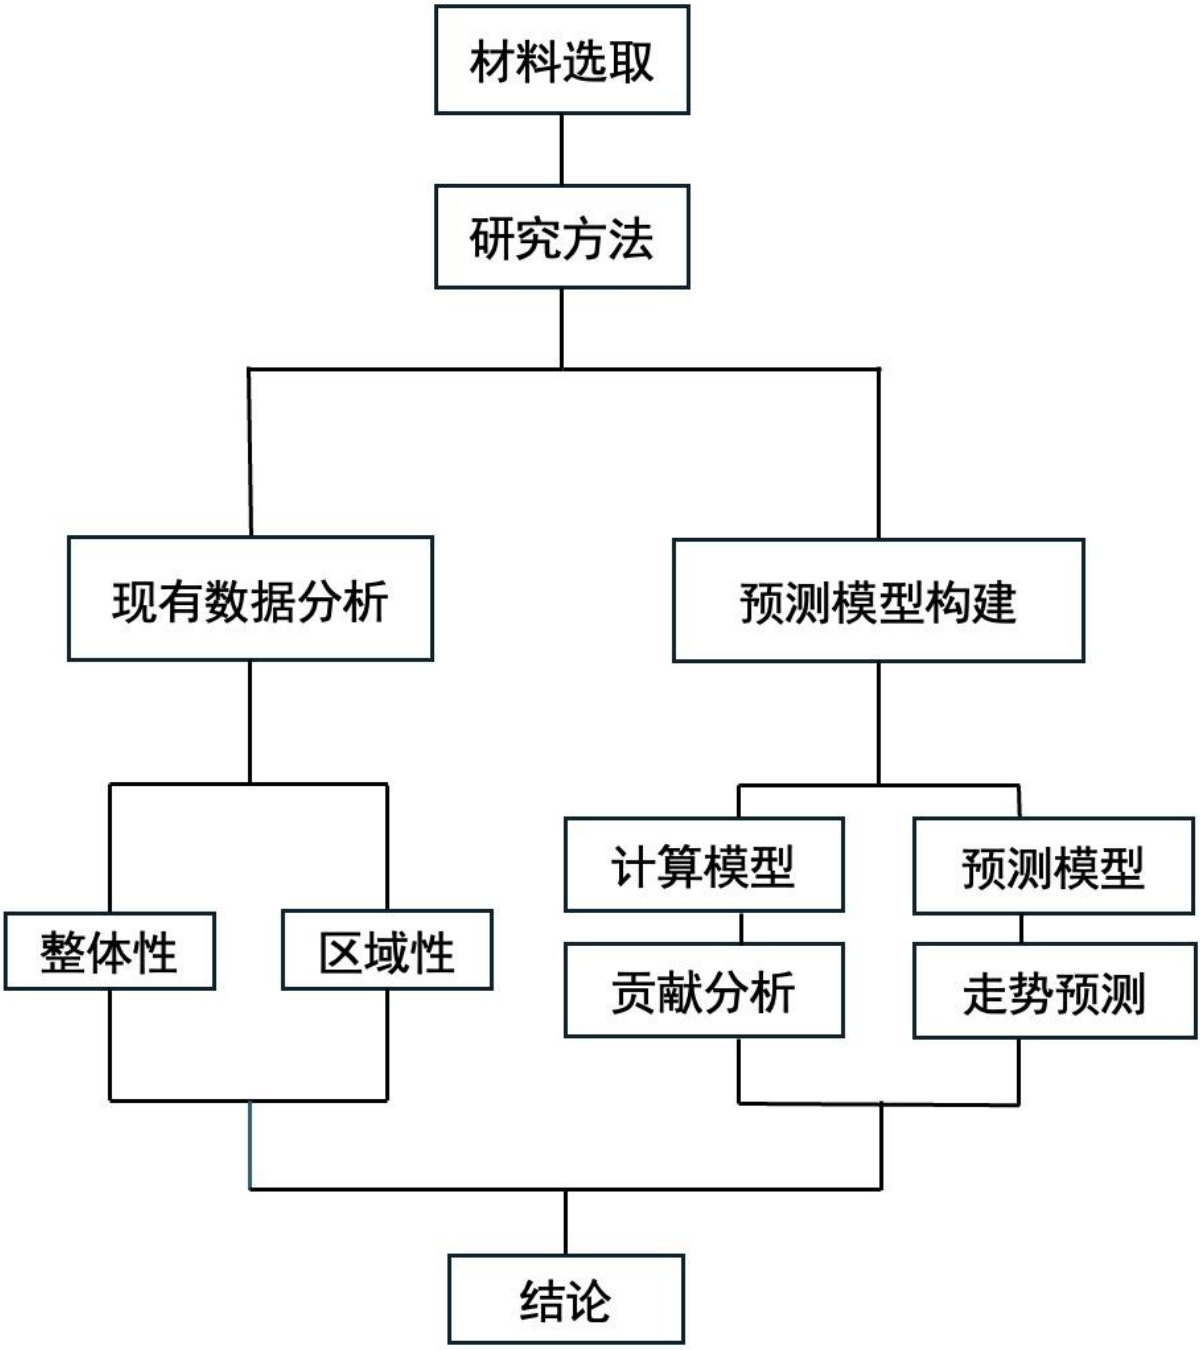



图 1 研究思路图

# 二、材料与方法

## （一）研究区域及数据来源

### 1.研究区域

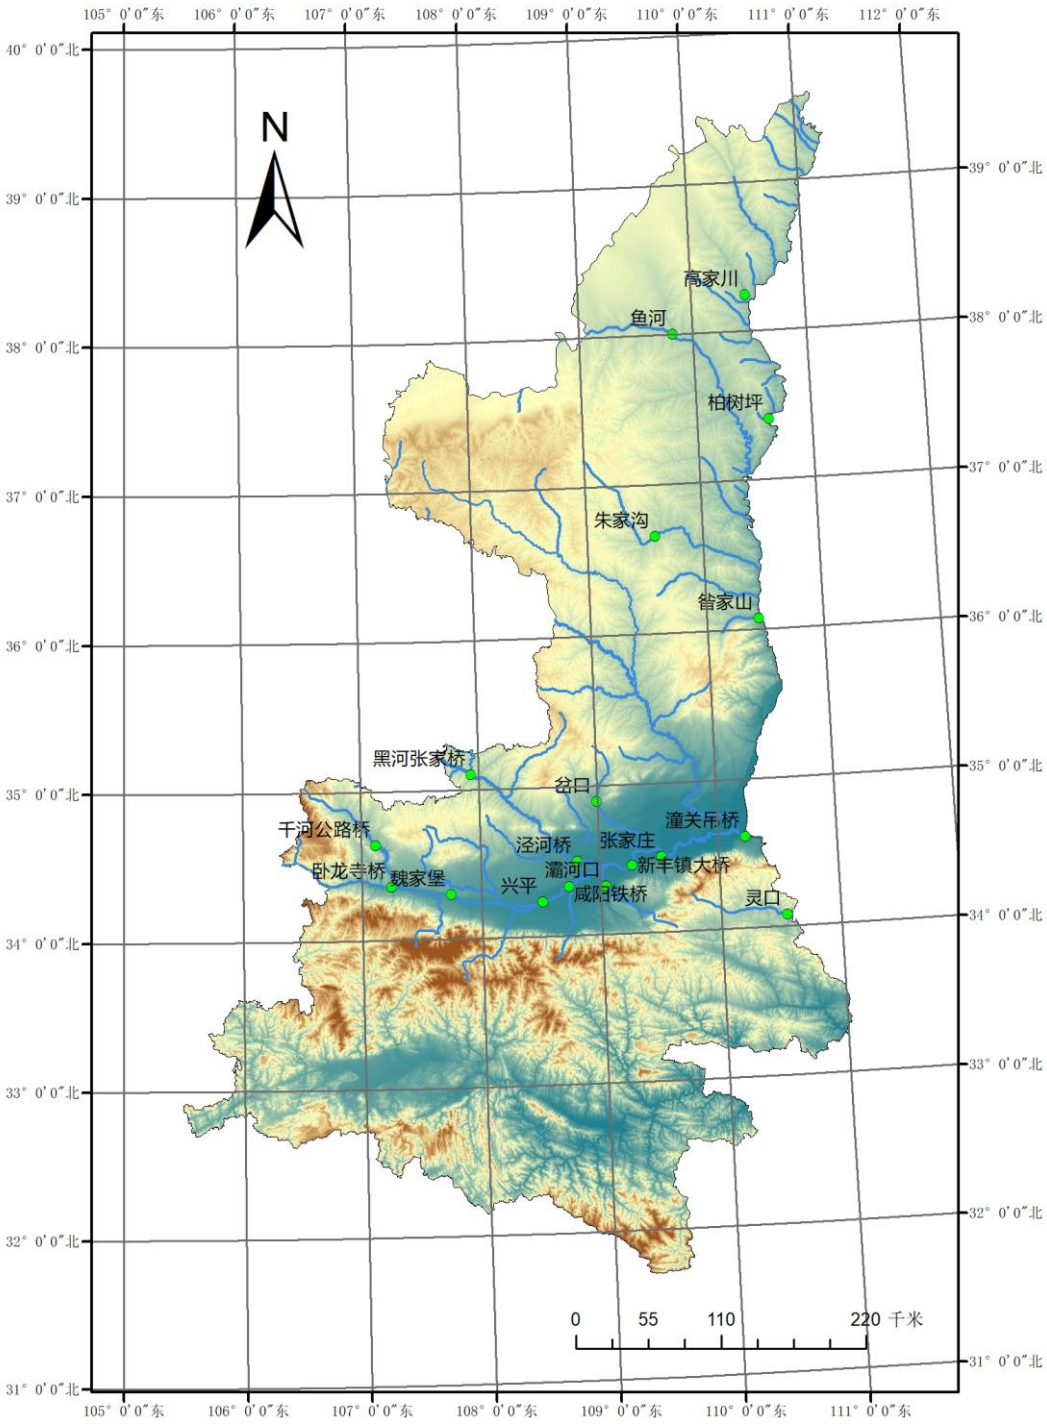



图 2 研究区域图

黄河发源于青藏高原巴颜喀拉山北麓的约古宗列盆地，自西向东分别流经青海、四川、甘肃、宁夏、内蒙古、陕西、山西、河南及山东 9 个省（自治区），最终在山东省东营市垦利区注入渤海，干流全长约 5464 千米，流域面积约 75.2 万平方千米，地理位置介于北纬 32° 10′ ～41° 50′，东经 95° 53′ ～119° 05′ 之间。陕西省位于中国内陆腹地，地处东 105° 29′ ～111° 15′，北纬 31° 42′ ～39° 35′ 之间。全省总面积 20.56 万平方千米。如图所示，结合中国环境监测总站的发布的水质数据完整度，本研究挑选陕西省国控断面 18 个进行研究，分别为高家川(S1)、鱼河(S2)、柏树坪(S3)、朱家沟(S4)、昝家山(S5)、潼关吊桥(S6)、新丰镇大桥（S7)、咸阳铁桥（S8)、兴平（S9)、魏家堡（S10)、卧龙寺桥（S11)、灵口（S12)、岔口(S13)、泾河桥（S14)、灞河口（S15)、张家庄（S16)、黑河张家桥（S17)、千河公路桥（S18)，位置均在图上标出。

**2.研究数据**

本研究数据由水质数据和 GIS 数据组成，水质数据来源于中国环境监测总站国家地表水实时监测数据发布系统(https://szzdjc.cnemc.cn:8070/GJZ/Business/Publish/Main.html)，本文收集 2021 年 1 月至 2025 年 4 月逐月水质数据和逐日(每 4h 发布一次)水质自动监测数据，水质指标包含为《地表水环境质量标准》（GB 3838-2002）中除粪大肠菌群以外的水质指标，即：水温(T)、pH、溶解氧(DO)、高锰酸盐指数、化学需氧量(COD)、五日生化需氧量(BOD5)、氨氮(NH3-N)、总磷 (TP)、总氮(TN)、铜(Cu)、锌(Zn)、氟化物(F-)、硒(Se)、砷(As)、汞(Hg)、镉(Cd)、六价铬(Cr6+)、铅 (Pb)、氰化物、挥发酚、石油类、阴离子表面活性剂(LAS)和硫化物(S2-)这 23 项指标，以及浊度(ZD)和电导率(Ec)，共计 25 项指标；逐日水质自动监测数据监测水质指标包括 pH、溶解氧(DO)、高锰酸盐指数、氨氮(NH3-N)、总磷(TP)和总氮(TN)，共计 6 项。由于数据量大小原因，本文在除 PCA 分析以外的数据均使用逐日水质自动监测数据为代表进行分析。数据处理使用 Python 3.9.13、Pycharm 2023.1.5 和 Conda 22.9.0。

GIS 数据包括陕西省 30 米分辨率数字高程模型（DEM）数据黄河流域基础地理数据集合，均来自地理空间数据云网站(https://www.gscloud.cn/home)。分析以上 GIS 数据采用 ArcGIS 10.8 软件。

## （二）研究方法

### 1.M-K 趋势检验

Mann-Kendall 趋势检验（M-K 趋势检验）作为经典的非参数统计方法，在时间序列趋势分析领域应用广泛，用于判断一个时间序列数据是否存在显著的单调趋势。该方法由 Mann 于 1945 年提出，Kendall 在 1975 年对其进行了扩展，因此得名 M-K 检验，其基本思想是通过计算序列中各个数据点之间的秩次差异，来判断时间序列中是否存在趋势。检验的核心是通过对比序列中任意两个数据点的大小关系，计算出这些差异的符号。具体而言，假设我们有一个时间序列数据集，每一对数据点被用来判断是否存在单调的增减关系。如果大多数的数据对呈现增大的趋势，则表明序列可能有上升趋势；反之，则可能存在下降趋势。Hirsch 等学者[10]充分考量时间序列中季节性波动因素，对经典 M-K 趋势检验方法进行创新性改良[11]。通过引入针对性算法优化，使该方法能够有效捕捉并量化时间序列的季节性变化特征，极大提升了其在复杂时序数据分析场景下的适用性与准确性。

主要步骤：

1，数据排序：

对时间序列数据按时间进行排序，这是为了根据数据的先后关系来评估时间序列中的变化趋势。

2，计算统计量：

- 对于每一组数据$x_k$和$x_j$，如果 k＞j，计算$sgn(x_k - x_j)$;
- $sgn(x_k - x_j)$的计算规则为：
  - 如果$x_k$＞$x_j$，则该值为 1.
  - 如果$x_k$＝$x_j$，则该值为 0.
  - 如果$x_k$＜$x_j$，则该值为-1.

其中，$sgn(x_k - x_j)$是符号函数，用于表示两个数据点的差异。通过所有数据对之间的差异符号，能够了解数据的整体变化趋势。

3，计算统计量 S：

- 计算所有符号函数$sgn(x_k - x_j)$的和，得到统计量 S：

$$s = \sum_{i=1}^{n} \sum_{j=i+1}^{n} sg\,n(x_k - x_j) \qquad \text{公式 1}$$

S 统计量的值体现了时间序列数据整体的单调性，若 S 值为正，表示数据总体呈现上升趋势；若为负，则说明数据总体呈现下降趋势。

4，标准化统计量：

使用 Z 方法对计算的统计量 S 进行标准化处理：

- 如果 S＞0，则 Z 为正，表示存在上升趋势；
- 如果 S＜0，则 Z 为负，表示存在下降趋势；
- 如果 S＝0，则 Z 等于零，表示数据中没有显著趋势。

计算 Z 统计量时，还需要考虑数据的样本容量和方差，以确保结论的可靠性。Z 值通常符合正态分布，当样本容量较大时，Z 值可以用于进一步的假设检验。

判断结果：

根据标准化的 Z 值进行假设检验，确定趋势的显著性。假设检验的零假设为“数据没有趋势”（即序列随机），备择假设为“数据存在单调趋势”。如果 Z 值的绝对值较大，表明序列存在显著的单调趋势。

通过与显著性水平（例如 5%）的比较，判断是否拒绝零假设。如果拒绝零假设，表示数据中存在显著的上升或下降趋势。

M-K 趋势检验的优点在于其非参数性质，使得它不要求数据符合特定的分布，适用于各种类型的时间序列数据，尤其适合非正态分布的情况。此外，M-K 检验计算简单且易于实现，无需对数据进行复杂的转化或假设检验，具有较强的适应性。本研究采用经典 Mann-Kendall 趋势检验与经季节性改良的 M-K 检验相结合的方式，系统剖析水质变化趋势。

**2.层次聚类分析**

层次聚类（Hierarchical Clustering）是一种常用于无监督学习的聚类分析方法，通过递归地合并或拆分数据，构建树状图（Dendrogram）来展示数据的层次结构。层次聚类有两种基本方法：凝聚式聚类（自底向上）和分裂式聚类（自顶向下）。凝聚式聚类从每个数据点开始，逐步合并最相似的数据点，直到所有数据点合并为一个簇；而分裂式聚类则从一个簇开始，逐步将其分裂成更小的簇。

层次聚类的核心在于定义簇与簇之间的相似性，常见的距离度量有欧氏距离、曼哈顿距离、皮尔逊相关系数和余弦相似度等，其中欧氏距离与曼哈顿距离最为常用。

欧氏距离(Euclidean Distance)用于衡量两个点之间的直线距离，公式为：

$$d(x,y)=\sqrt{\sum_{i=1}^{n}(x_i-y_i)^2} \quad \text{公式 2}$$

曼哈顿距离（Manhattan Distance）度量每个坐标轴的绝对距离之和，公式为：

$$d(x,y)=\sum_{i=1}^{n}|x_i-y_i| \quad \text{公式 3}$$

皮尔逊相关系数（Pearson Correlation）衡量两个变量间的线性相关性，而余弦相似度（Cosine Similarity）用于文本数据和高维稀疏数据，通过余弦值衡量向量间的角度相似性。

此外，聚类的链接方式也有不同，常见的有单链接、完全链接、平均链接和质心链接，不同的方式会影响最终的聚类效果，常用的几种计算方式有：

单链（Single Linkage）：

两个簇中最小距离的数据点之间的距离，即最近邻距离，适合发现细长或不规则形状的簇。

$$d(A,B)=\min_{a\in A,b\in B}\|a-b\| \quad \text{公式 4}$$

全链（Complete Linkage）：

两个簇中最大距离的数据点之间的距离，即最远邻距离，适合球形分布。

$$d(A,B)=\max_{a\in A,b\in B}\|a-b\| \quad \text{公式 5}$$

平均距离（Average Linkage）：

两个簇中所有点对之间的平均距离，常用于减少单链和全链方法的极端情况

$$d(A,B)=\frac{1}{|A||B|}\sum_{a\in A}\sum_{b\in B}\|a-b\| \quad \text{公式 6}$$

质心距离（Centroid Linkage）：

计算两个簇质心之间的距离，即簇中所有点的平均位置

$$d(A,B)=\|\mu_A-\mu_B\| \quad \text{公式 7}$$

其中$\mu_A$和$\mu_B$分别是簇 A 和簇 B 的质心。

以凝聚层次聚类为例，以下是详细步骤：

1.计算初始距离矩阵：

计算数据集中每两个点之间的距离，将距离存入矩阵中。常用的距离度量是欧氏距离。

2.初始化每个点为一个单独的簇：

初始时，每个数据点都视为一个独立的簇。

3.合并最近的簇：

查找距离矩阵中距离最近的两个簇，合并这两个簇，并更新簇之间的距离。

4.更新距离矩阵：

更新新的簇与其他簇之间的距离。

重复步骤 3 和 4，直到所有点合并成一个簇或达到预设的聚类数。

5.树状图的生成

在合并簇的过程中，记录每次合并的簇对及其距离，即可构建一个树状图以展示数据集在不同距离阈值下的聚类结构。

层次聚类的优点在于不需要预先指定簇的数量，生成的树状图能够帮助用户根据需求选择不同的切割层次；它还适用于处理不规则形状的数据，有助于可视化并理解不同聚类之间的关系。然而，它的缺点是计算复杂度较高且调整较为困难。层次聚类对噪声处理不敏感，可能将噪声误归为独立簇，并且某些不当的链接方式会影响聚类结果的准确性。

**3. 新型综合水质指数法(WQI-DET)**

WQI-DET（水质指数-环境趋势检测）是传统水质指数（WQI）的改进版本，专门用于评估中国湖泊和水库的水质。这个修改后的指数根据中国的水质分类标准进行了定制，将水质分为五个等级：优、良、中、差、劣。与传统的水质指数 0 到 100 的范围不同，WQI-DET 的范围更广，从负无穷（极差水质）到 100（极优水质），使得能够更清晰地区分不同的水质水平，包括极差的水质状况。

WQI-DET 使用了 12 个水质参数，包括溶解氧、化学需氧量、总磷以及重金属如铬、镉、砷等。通过对这些变量的评估，WQI-DET 提供了全面的水质评价，可以在不同的地点和时间进行监测，从而检测出水质的急剧变化和渐进性变化。该指数已被用于监测中国 140 多个湖泊和水库的水质，数据覆盖了 2005 年至 2017 年共 13 年的时间。

WQI-DET 的计算方法如下:

$$WQI-DET_i^j = 100 - max\left(0, \frac{C_{ij}-C_i^I}{C_i^v-C_i^I}\right) \times 100 \quad \text{公式 8}$$

结合徐祖信的综合水质标识指数评价方法[3]，我们有

$$WQI-DET^j = \frac{1}{n}\left(WQI-DET_1^j, \ldots, WQI-DET_n^j\right) \quad \text{公式 9}$$

式中，$WQI-DET^j$为水样$j$的新型综合水质指数计算值，$WQI-DET_i^j$为水样$j$中水质指标 i 的 WQI-DET 计算值，$C_{ij}$为水样$j$中水质指标 i 的浓度，$C_i^I$和$C_i^v$分别为 GB3838-2002 规定的 I 类水体和 V 类水体水质指标的限值。WQI-DET 取值范围为$(-\infty, 100]$，数值越大，水质越好，反之则越差。可根据 WQI-DET 计算结果按表 1 进行水质分级。

表 1 水质等级表

| WQI-DET | ≥80 | [60, 80) | [40, 60) | [20, 40) | [0, 20) | < 0 |
|---|---|---|---|---|---|---|
| 水质等级 | 极优 | 优 | 良 | 中 | 差 | 极差 |

## 4. 主成分分析

主成分分析（Principal Component Analysis，PCA）作为经典的多元统计分析方法，在数据处理领域发挥着重要作用，常被应用于数据降维、特征提取与数据探索场景。其核心原理是通过线性变换，将原始变量重新组合成一组互不相关的新变量（即主成分），在压缩数据维度的同时，最大程度地保留原始数据中的关键信息。这一特性使其在水质评价分析中备受青睐，能够有效识别和筛选出影响水质的主要污染因子，为水质监测与治理提供科学依据。

在开展主成分分析前，巴特利球形检验（Bartlett's Test of Sphericity）是不可或缺的前置步骤。该检验旨在验证数据是否符合主成分分析的基本前提条件，即判断原始变量间是否存在显著的线性相关性。具体而言，若巴特利球形检验的 P 值小于常用的显著性水平阈值（通常设定为 0.05），则表明变量间存在较强的相关性，数据适用于主成分分析，能够通过降维获取有价值的主成分；反之，当 P 值大于显著性水平时，意味着变量间相关性较弱，直接进行主成分分析可能难以实现有效降维，此时需考虑调整分析策略，或尝试其他更适合的降维方法，以确保数据分析结果的可靠性和有效性。

**5.机器学习方法**

①SHAP 分析法

SHAP（SHapley Additive exPlanations）分析方法是一种基于博弈论的解释机器学习模型输出的技术，它通过量化每个特征对模型预测结果的贡献，提供了一个统一的框架来解释复杂机器学习模型的预测过程。SHAP 分析借鉴了博弈论中的 Shapley 值，这一概念最早用于公平地分配合作博弈中各个参与者的贡献。在 SHAP 分析中，模型的特征被视为博弈中的“玩家”，模型的输出（即预测值)则被看作博弈的“收益”。通过计算每个特征对预测结果的“边际贡献”，SHAP 能够解释每个特征在最终预测中的重要性。

SHAP 值的计算是基于对所有特征子集的评估，其数学公式为：

$$\emptyset^i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N|-|S|-1)!}{|N|!} \left(v(S \cup \{i\}) - v(S)\right) \qquad \text{公式 10}$$

其中$\emptyset^i$是特征 i 的 SHAP 值，S 是特征子集（不包括特征 i）,N 是特征的总集，$v(S)$是特征集 S 的模型输出，$v(S \cup \{i\})$是特征集 S 加上特征 i 后的模型输出结果。

由于计算 SHAP 值涉及对所有可能的特征组合进行评估，这一过程会极其耗时，因此通常使用蒙特卡洛积分方法来估算 SHAP 值。通过对背景样本进行随机采样，利用待解释样本的特征替代背景样本中的对应特征，并在计算中求取平均值，从而实现对特征贡献的估算。这种方法将原本无法直接计算的积分转化为通过样本求和的可计算形式。当遍历所有可能的联盟之后，就可以得到 j 的 SHAP 值的估计值为：

$$\hat{\phi}_j^{(i)} = \Sigma_{S \subseteq \{1,\ldots,P\} \setminus \{j\}} \frac{|S|,(p-|S|-1)!}{P!} \hat{\Delta} s_j \qquad \text{公式 11}$$

在机器学习和深度学习领域，尽管像深度神经网络、XGBoost、LightGBM 等复杂模型在预测性能上表现优秀，但它们往往被视为“黑箱”模型，难以理解其决策过程。SHAP 为解决这一问题提供了有效的工具，通过为每个特征分配贡献值，从而提升复杂模型的可解释性，帮助用户更好地理解模型的预测逻辑。

②Extra Trees（极端随机森林）

Extra Trees 是 Extremely Randomized Trees 的缩写，译为极端随机森林，它是随机森林算法（Random Forest）的一个变种，而随机森林又属于集成学习中 Bagging 算法的延展。

对于训练数据集，我们通过训练一系列个体学习器，并通过一定的结合策略将它们组合起来，形成一个强有力的学习器，以达到博采众长的目的，这就是集成学习的概念。Bagging（Bootstrap Aggregating）是一种典型的并行集成学习方法，它通过对原始训练集进行有放回的随机采样，生成多个不同的子数据集，并在这些子集上分别训练多个基学习器。最终，通过对所有基学习器的预测结果进行集成，如分类任务中采用投票法，回归任务中采用平均法，从而提升模型的稳定性和泛化能力。此外，约 36.8%的未被采样样本可以作为“包外数据”用于模型验证。随机森林是 Bagging 的扩展形式，它以决策树为基学习器，并在构建每棵树时引入特征选择上的随机性。具体做法是，在每个决策节点上，不是从所有特征中选最优划分特征，而是从随机选出的部分特征中选择最优的一个。这种策略使得基学习器之间差异更大，增强了模型的泛化能力。

Extra Trees（极端随机森林）进一步在随机森林的基础上加大了“随机性”。它与随机森林的主要区别有两点：一是训练集通常直接使用原始数据而非自助采样得到的样本；二是在确定划分属性后，不再寻找最优的划分点，而是直接在特征的取值范围内随机选择一个划分点。这种做法虽然增加了偏差，但显著降低了模型方差，在某些数据集上甚至能取得优于随机森林的效果。

Extra Trees 的分裂算法包括以下几个主要步骤：

1.分裂节点：首先，从当前节点的样本集中选择 K 个非常数的特征。然后，为每个特征选择一个随机分裂点，并通过计算每个分裂的得分，选择最优的分裂。

2.随机选择分裂：对于每个特征，选择该特征在当前子集中的最大值和最小值，并在这个区间内随机选取一个分裂点。

3.停止分裂：如果样本数小于预设的最小值，或者所有样本的特征值相同，或者输出值为常数，则停止分裂。

分数计算公式：

在分类任务中，分数$Score_C(s,S)$的计算公式为：

$$Score_C(s,S)=\frac{2I_c^s(S)}{H_s(S)+H_c(S)} \quad \text{公式 12}$$

其中$H_c(S)$是分类的熵，$I_c^s(S)$是分裂信息与分类之间的互信息。

在回归任务中，使用相对方差减少来计算分数：

$$Score_R(s,S)=\frac{var\{y|S\}-\frac{|S_l|}{|S|}var\{y|S_l\}-\frac{|S_r|}{|S|}var\{y|S_r\}}{var\{y|S\}} \quad \text{公式 12}$$

其中，$var\{y|S\}$是样本$S$中输出 y 的方差，$|S_l|$和$|S_r|$分别表示分裂后左子集和右子集的样本数。

Extra Trees 广泛应用于分类、回归任务，尤其在处理高维、复杂、大规模数据集时表现出色。它通过增加随机性和减少过拟合来提升模型的泛化能力，适用于许多实际问题中的数据建模任务。

# 三、结果与讨论

## （一）数据整体性处理及分析

### 1．正态性检验

Shapiro-Wilk 正态检验由 Shapiro 在 1965 年提出[12]，其原假设为数据符合正态分布。在显著性水平为 0.05 的情况下，我们对全部 18 个断面的 6 个指标全部使用 Shapiro-Wilk 正态检验。结果显示所有断面的所有水质指标均不符合正态分布。

### 2．斯皮尔曼相关系数

表 2 斯皮尔曼相关系数表

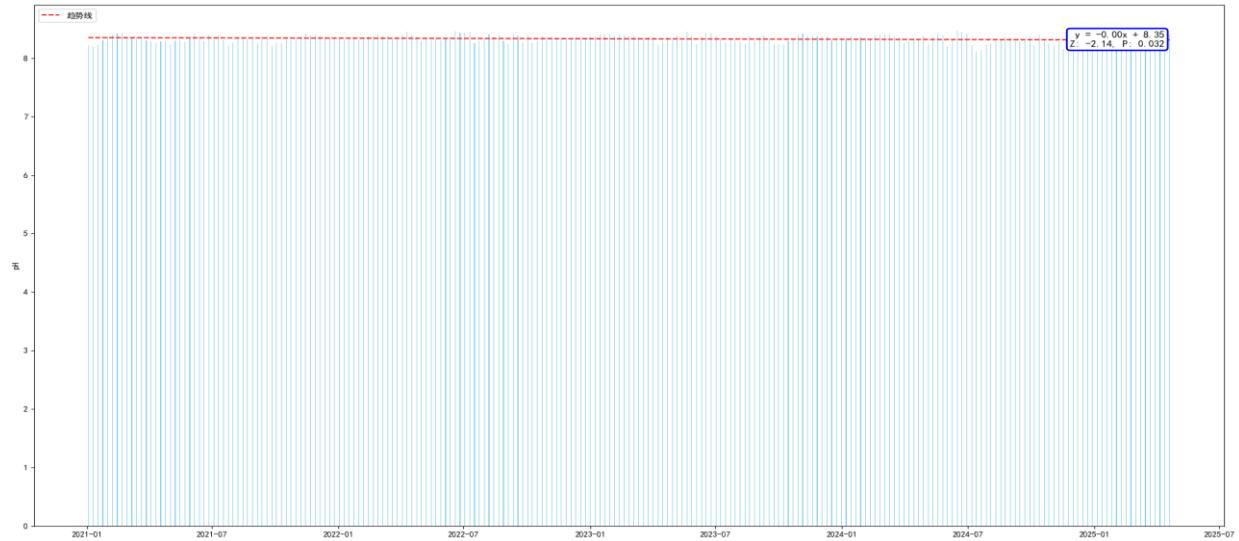
| | pH | 溶解氧 | 高锰酸盐指数 | 氨氮 | 总磷 | 总氮 |
|---|---|---|---|---|---|---|
| pH | 1 | | | | | |
| 溶解氧 | 0.3831 | 1 | | | | |
| 高锰酸盐指数 | -0.1671 | -0.1888 | 1 | | | |
| 氨氮 | -0.2688 | 0.1355 | 0.3243 | 1 | | |
| 总磷 | -0.2997 | -0.353 | 0.674 | 0.3846 | 1 | |
| 总氮 | -0.2811 | 0.1735 | 0.4054 | 0.4641 | 0.3379 | 1 |

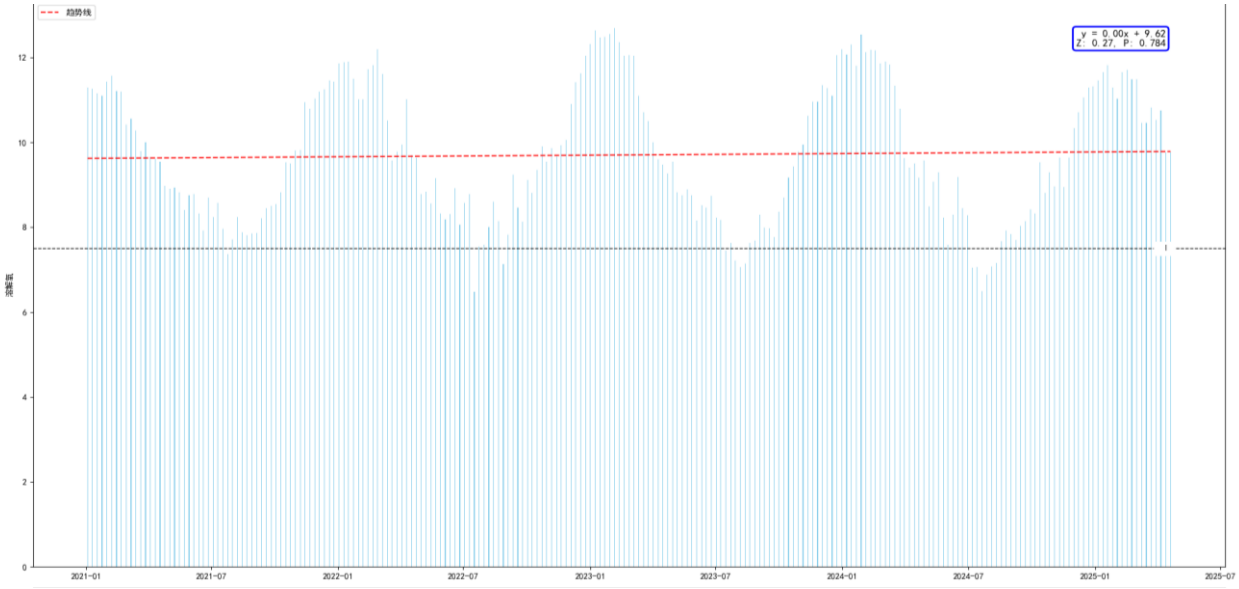
通过计算各水质指标的斯皮尔曼相关系数，构建相关性矩阵（详见表 2），剖析水质指标间的内在关联。结果显示，各指标间呈现出不同程度的正负相关性：溶解氧与总磷呈显著负相关关系，即当水体中溶解氧含量较高时，总磷浓度相对较低。

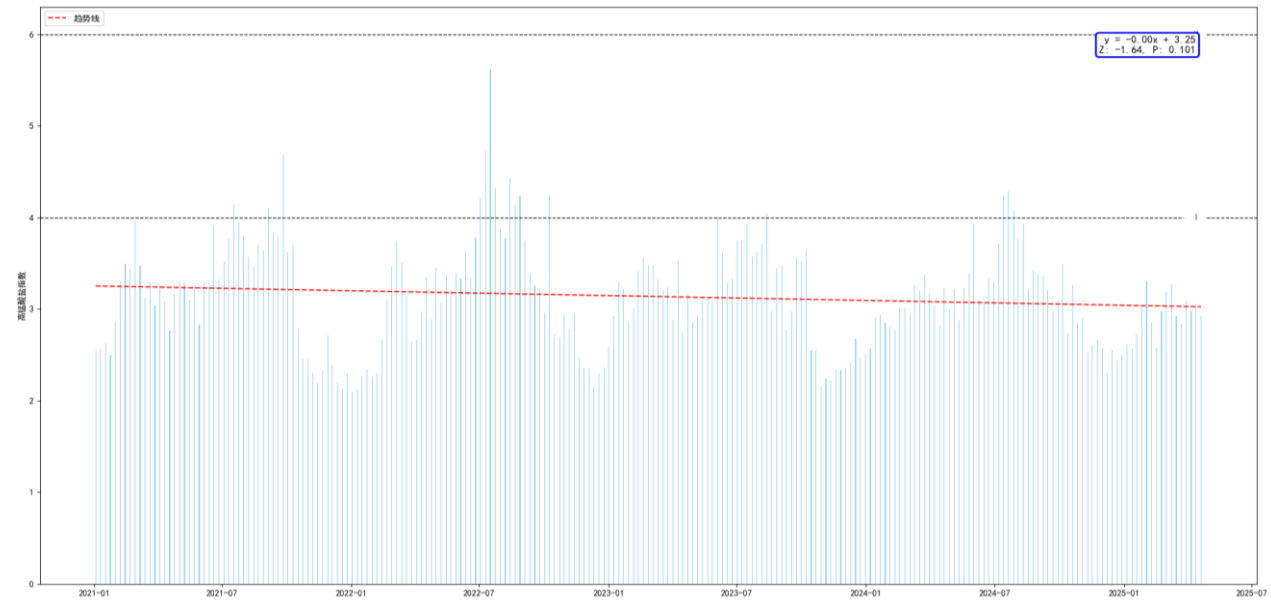
高锰酸盐指数与总磷之间存在较强的正相关关系，暗示在氧化还原体系中，具备较高氧化能力的水体更易富集磷元素。高锰酸盐指数作为反映水体中还原性物质含量的重要指标，其数值偏高可能代表水体氧化性较强，这种环境条件或许更有利于磷的溶解、迁移与积累。

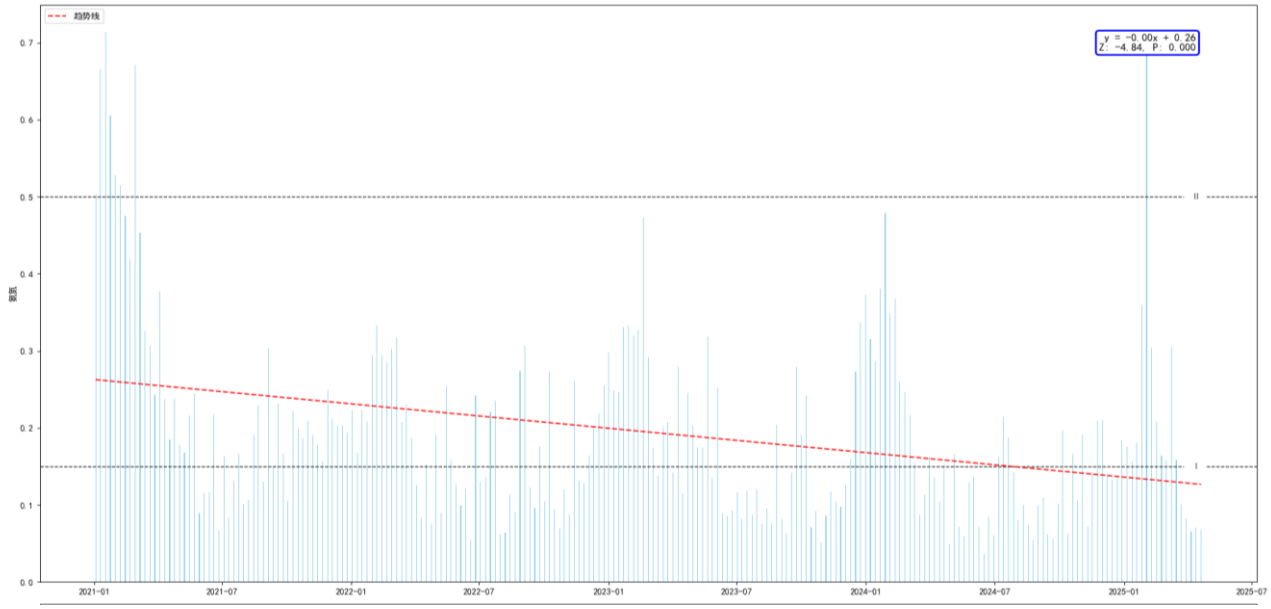
此外，氨氮与总氮之间呈现出高度相关性，表明水体中的氮源存在紧密联系。当氨氮浓度上升时，总氮浓度往往随之增加，这意味着氨氮作为水体氮源的重要组成部分，其含量变化会直接影响总氮水平，也侧面反映出两者在氮循环过程中存在复杂的转化关系与协同效应。

### 3.M-K 趋势检验




趋势线
y = -0.00x + 3.25
Z: -1.64, P: 0.101
I
2021-01
2021-07
2022-01
2022-07
2023-01
2023-07
2024-01
2024-07
2025-01
2025-07


趋势线
y = -0.00x + 0.26
Z: -4.84, P: 0.000
II
I
2021-01
2021-07
2022-01
2022-07
2023-01
2023-07
2024-01
2024-07
2025-01
2025-07

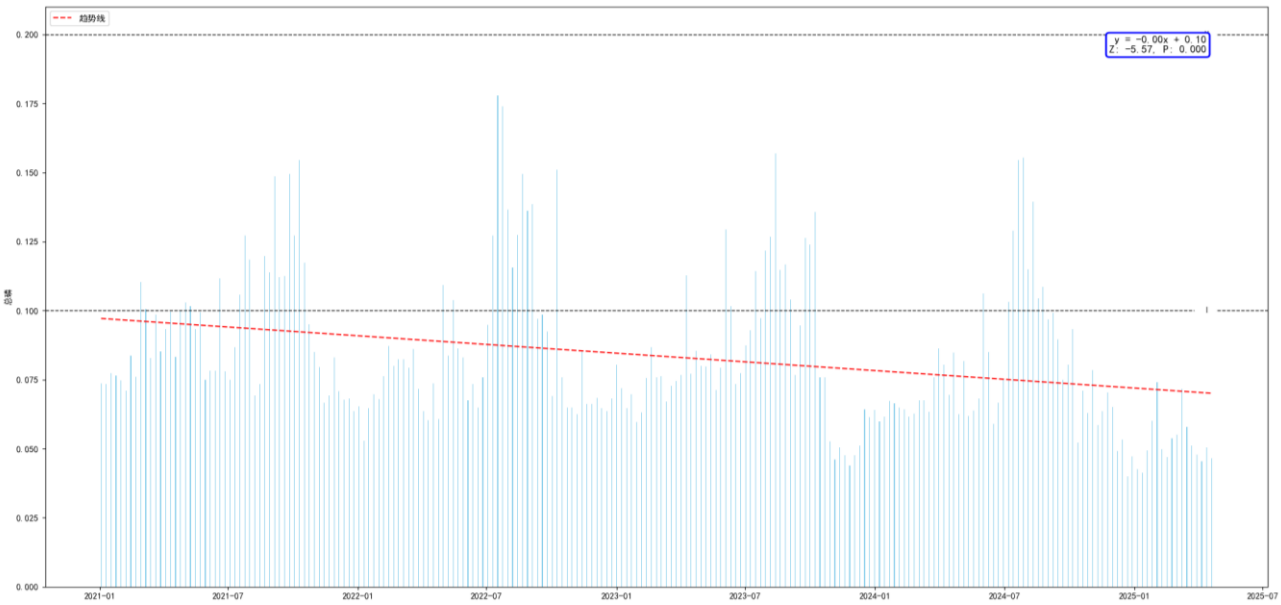

趋势线
y = -0.00x + 0.10
Z: -5.57, P: 0.000
I
2021-01
2021-07
2022-01
2022-07
2023-01
2023-07
2024-01
2024-07
2025-01
2025-07




图 3 各变量 M-K 趋势图

为排除异常值，对整个陕西省黄河流域计算各水质指标的周均值，做 pH、溶解氧、高锰酸盐指数、氨氮、总磷、总氮及 WQI-DET 七个指标进行 M-K 趋势检验并基于中国地表水质量标准(GB 3838-2002)进行评价。结果如图 3 所示。

图中可以看出在显著性水平为 0.05 的标准下，陕西段黄河流域整体上、溶解氧和高锰酸盐指数变化较为稳定，pH 长期处于 8 以上的弱碱性水平，溶解氧和高锰酸盐指数在Ⅰ类线上下波动，总体而言表现较好且稳定。氨氮、总磷、总氮和 WQI-DET 有明显下降的趋势，其中氨氮在 2021 年后，在今年首次再现了高峰，需要多加注意，总磷则是同样在Ⅰ类与Ⅱ类间波动，偶有Ⅲ类水平发生。总氮的状况不容乐观，长期保持着国家Ⅴ类水指标的两倍以上，峰值甚至能够达到

五倍以上。最终 WQI-DET 显示陕西黄河水质在中等级为主并上下波动，证明黄河水治理形式依旧严峻，但明显的下降趋势也能体现治理作用。

值得注意的是，我们在图像中能明显发现溶解氧、高锰酸盐指数、氨氮和 WQI-DET 指标的周期性变化，这可能与河流的周期性活动有关，我们将在下文的聚类分析中继续讨论。

## 4.层次聚类分析

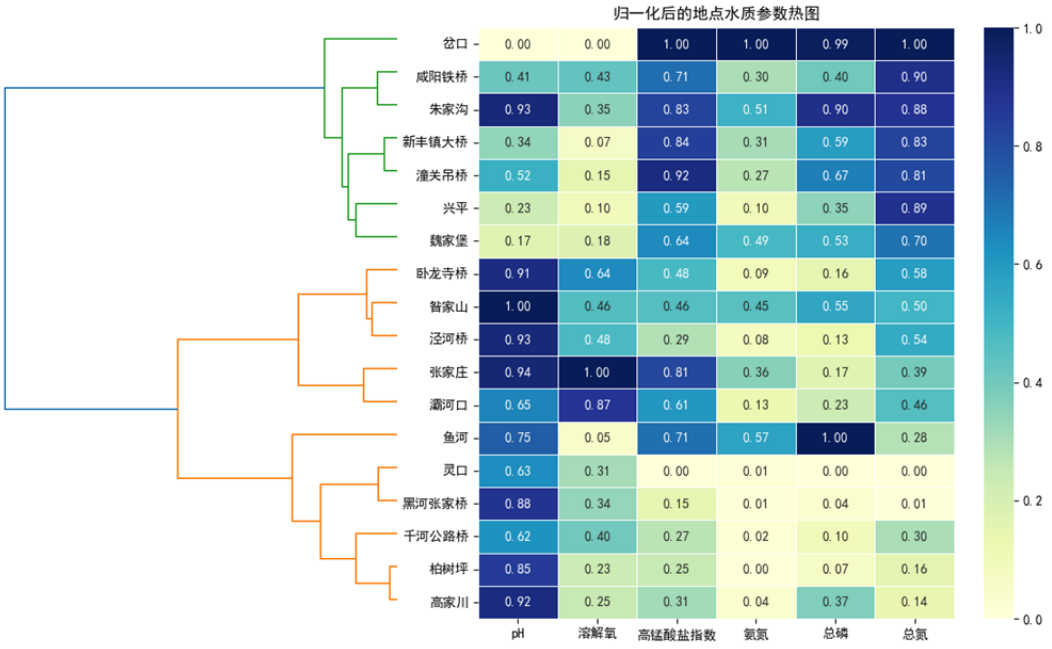



图 4 空间层次聚类分析图

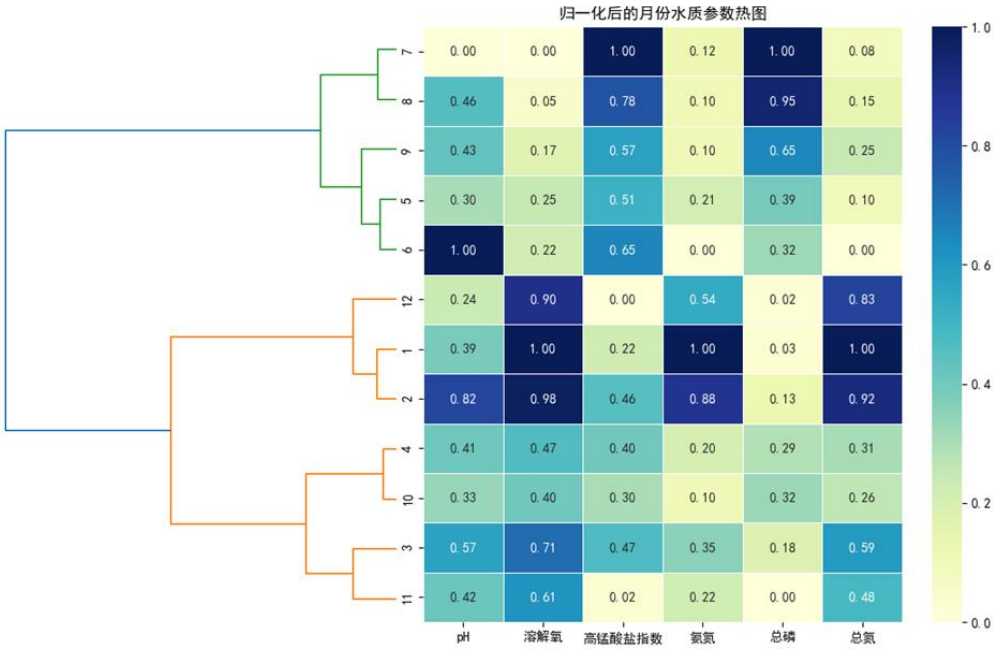



图 5 时间层次聚类分析图

空间聚类分析中看到，陕西省黄河流域断面水质可分为三大类，第一类为以高家川、柏树坪和灵口为代表的近黄河干流类，第二类为其余断面组成的近渭河干流类，说明陕西省黄河流域水质与水体分布具有一定的相关性。

从时间聚类分析中可以看出，水质数据可分为，其中 3-4 月、11-12 月为一类，5-9 月为一类，12 月-次年 2 月为一类，3 类大体上代表平水期、丰水期与枯水期。从中选取 5-9 月为汛期，其余为非汛期，结合上文分析发现溶解氧、高锰酸盐指数、氨氮和 WQI-DET 指标在汛期与非汛期有着明显的周期性趋势。

## (二)数据区域性处理及分析

### 1.各指标分析

通过层次聚类分析，我们划分出了渭河干流区域汛期与非汛期的季节性特征并分别对各个断面整体时期和汛期与非汛期做季节性 M-K 趋势检验。并将结果制成如下图表：

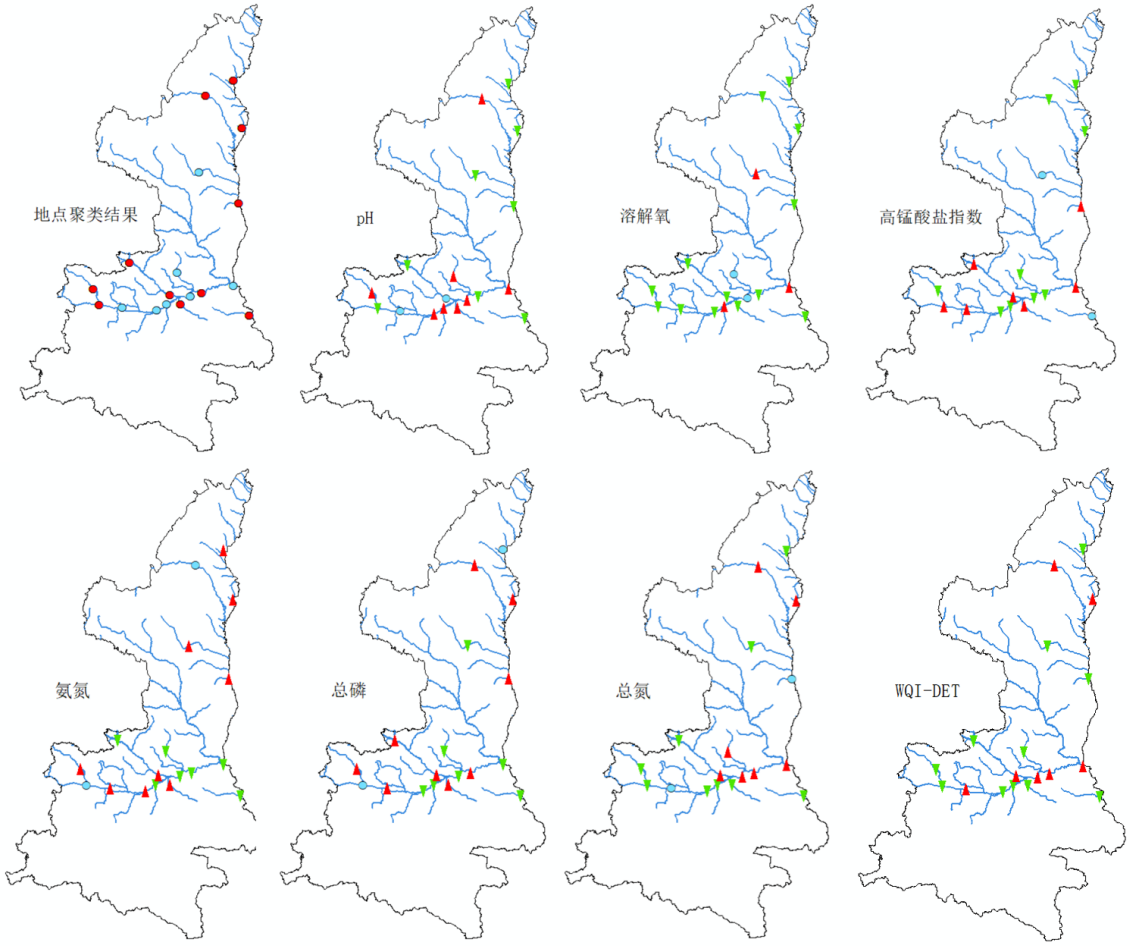



图 6 汛期 M-K 检验结果图

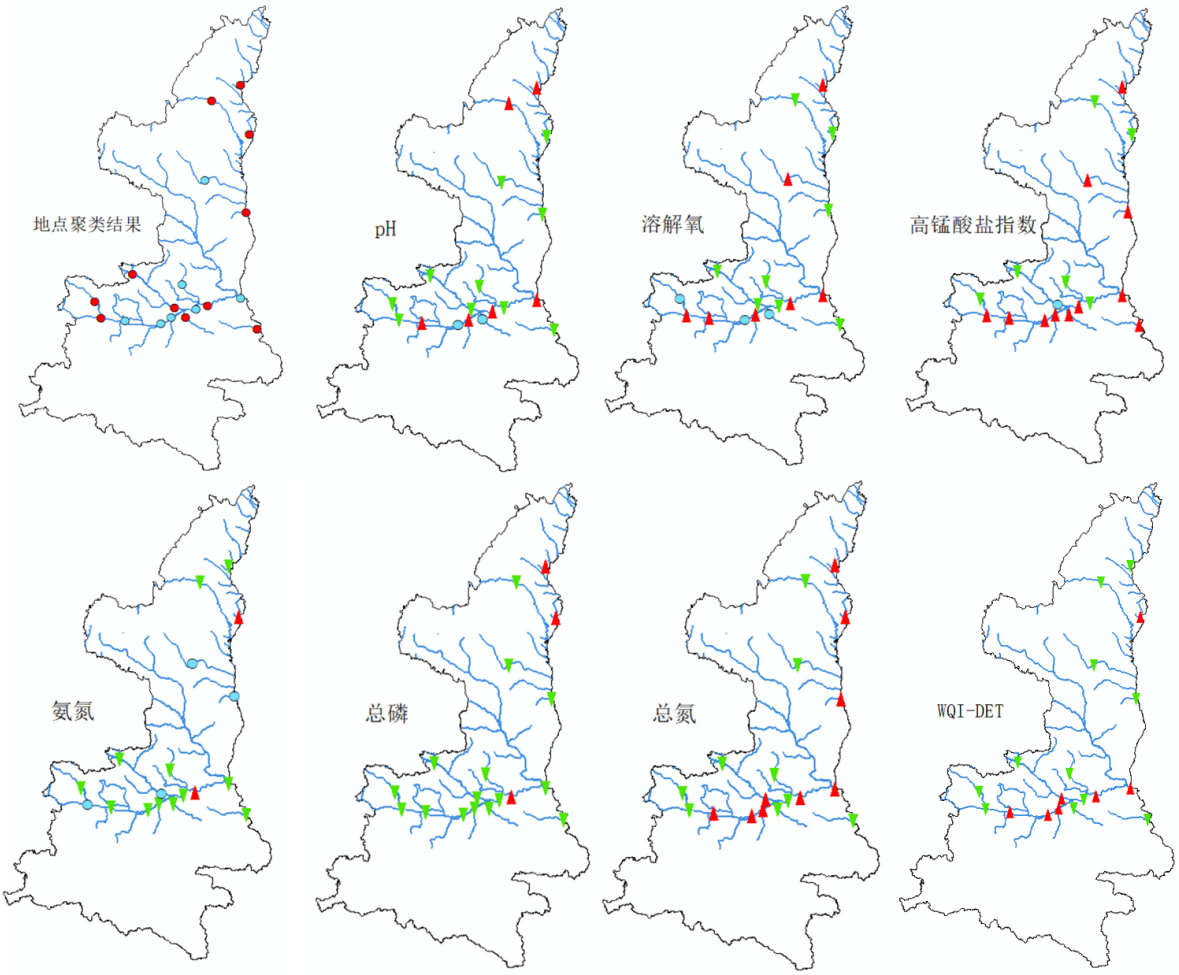



图 7 非汛期 M-K 检验结果图

通过对汛期与非汛期的季节性 M-K 趋势分析，并结合地点聚类结果对比可知，各水质变量的变化趋势呈现显著时空差异。pH 值在汛期与非汛期的变化趋势较为一致，且与地点聚类分析结果高度契合，反映出其变化规律的稳定性与空间同质性。而溶解氧、氨氮及总磷的季节性特征极为突出，尤其是氨氮与总磷，在非汛期于陕西省全域范围内均呈现明显下降趋势，表明这些指标受季节性水文条件影响显著。高锰酸盐指数与总氮的变化趋势则更为复杂，其演变特征兼具时间动态性与空间异质性，是多种时空因素综合作用的结果。

**2. 主成分分析**

由于时间与空间条件的差异，各季节间的水质状况呈现出明显的不同。有鉴于此，本研究依据聚类分析的成果，对流域在时间维度和空间维度上展开了分类处理。随后，选取高锰酸盐指数和六价铬作为重金属污染代表，总氮和总磷作为富营养污染代表，氟化物和氰化物作为有毒污染代表，开展主成分分析

工作。在实施主成分分析之前，为判断上述六项指标是否适宜进行因子分析，我们进行了 Bartlett 球形检验，具体的检验结果见下表呈现。

表 3 主成分分析结果表

| 分类 | Bartlett 球形检验显著性 | | 特征值$\lambda > 1$的主成分贡献率/% | | | |
|---|---|---|---|---|---|---|
| | 近似卡方 | 显著性 | PC1 | PC2 | PC3 | PC4 |
| 近渭河 | 3939.746 | <0.01 | 29.460 | 27.100 | — | — |
| 近黄河 | 5700.484 | <0.01 | 26.674 | 22.029 | 17.576 | — |
| 汛期 | 1909.793 | <0.01 | 41.591 | 23.766 | — | — |
| 非汛期 | 8350.976 | <0.01 | 36.804 | 22.654 | — | — |

1）“–”表示该分组 PC4 对应特征值 $\lambda$ <1， 故不列出

基于主成分分析（PCA），研究筛选出特征值 λ>1 的有效主成分。空间维度上，近渭河干流类的第一主成分中，氟化物和氰化物权重显著，表明该区域存在有毒物质污染风险；六价铬与高锰酸盐指数的高载荷，进一步暗示重金属与有机物污染并存，推测其污染源或与工业活动密切相关。相较之下，近黄河干流类的第一主成分以高锰酸盐指数和总磷贡献为主，揭示该区域水质问题聚焦于有机物降解、磷元素引发的富营养化及氧化还原失衡，且氟化物与氰化物影响较弱，反映出以农业面源与生活污染为主的差异化污染特征。

时间维度上，研究将年中 5-9 月划分为汛期，其余时段归为非汛期。分析发现，全年 PC1 均由高锰酸盐指数、总氮和总磷主导，证实流域水质长期受有机污染与富营养化问题困扰。

时空联合分析结果表明，主成分分析构建的时空分类体系，能够精准识别流域不同季节、区域的污染特征，为靶向治理提供科学依据。具体而言，近渭河干流类区域需强化工业源管控，重点削减氟化物、氰化物排放，同步推进重金属污染治理与有机物降解；近黄河干流类区域则应围绕农业面源与生活污水排放控制，降低高锰酸盐指数与总磷浓度，防范水体富营养化风险，同时可适当降低有毒物质管控优先级。

## (三)水质预测模型构建

### 1．WQI-DET 计算模型

作为 WQI-DET 水质评价标准可以很好地评价当前水体的污染情况，但高频次的逐日 4h 监测数据难以做到时刻准确记录全部的指标，实际过程中，环境

总站总会遇到数据缺失的情况。因此需要根据已有的指标构建 WQI-DET 计算模型。本文以 pH 值缺失的情况为例。

按照 4：1 划分训练集与测试集，使用 lazypredict 库快速测试 Scikit-learn 库中所有回归模型的性能，并将结果制成如下泰勒图（性能过于相似或存在欠拟合问题的模型已省略）。

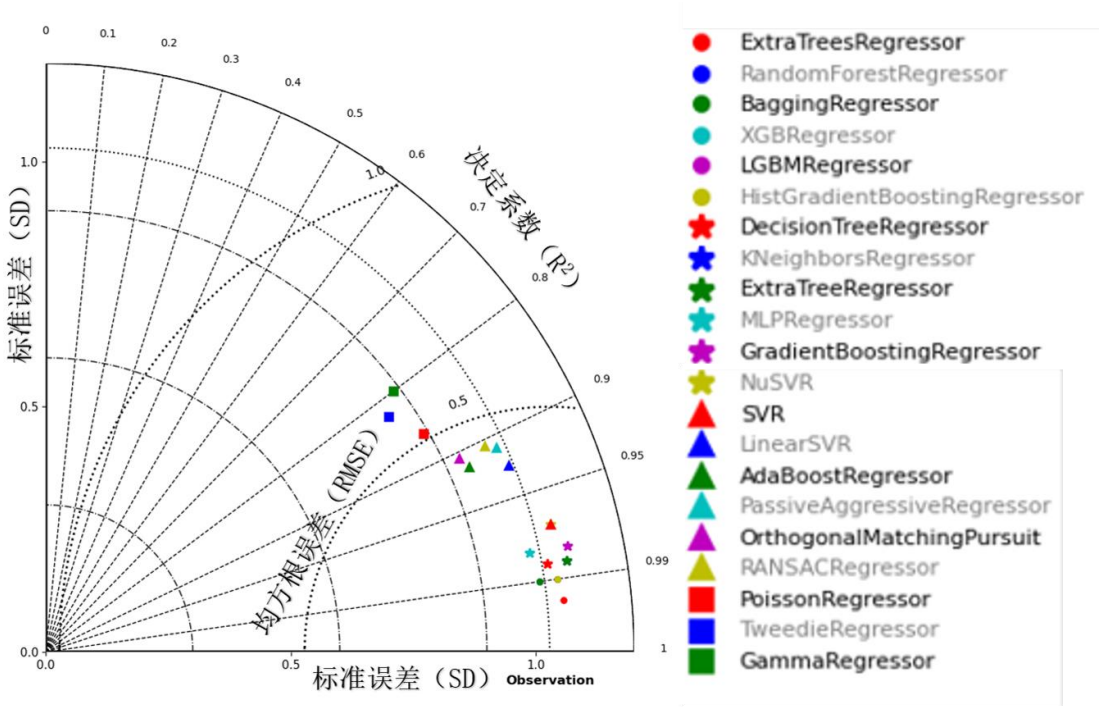



图 8 WQI-DET 计算模型泰勒图

综合全部 39 个模型的结果来看，ExtraTreesRegressor 有着最低的 RMSE 和最高的 $R^2$，相比其他模型更为稳健，作为 WQI-DET 计算模型的表现最好。

为观察各变量对 WQI-DET 的实际影响，对模型做 SHAP 分析并画图。

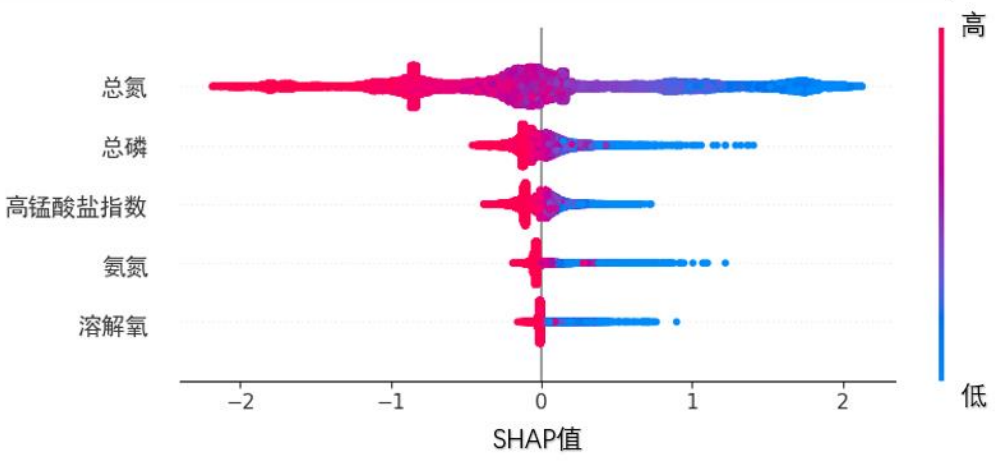



图 9 SHAP 分析图

从图中可以看到，总氮的 SHAP 值分布范围较广，覆盖了从负值到正值的区间。这意味着在不同情况下，总氮对 WQI-DET 的影响既可能是正向的（使 WQI-DET 升高），也可能是负向的（使 WQI-DET 降低）。并且其分布的宽度表明总氮对 WQI-DET 的影响波动较大，可能在某些条件下是影响 WQI-DET 的重要因素。总磷和氨氮的 SHAP 值大部分集中在正值区域，说明总体上其存在倾向于增加 WQI-DET 值。并且从其分布的集中程度来看，对 WQI-DET 的正向影响相对较为稳定，是使 WQI-DET 升高的一个重要因素。高锰酸盐指数和溶解氧的 SHAP 值也多在正值区域，表明它们对 WQI-DET 也有正向影响，相较于总磷，其分布范围稍窄一些，影响的稳定性也较好，也是影响 WQI-DET 的重要正向因素。

**2．WQI-DET 预测模型**

依据水质数据预测污染量未来走势，对于提前制定针对性的水质保护策略、有效预防水质恶化具有不可估量的重大意义。我们同样按照 4：1 划分训练集与测试集，使用 lazypredict 库快速测试 Scikit-learn 库中所有回归模型对水质预测的性能，并将结果制成如下泰勒图（性能过于相似或存在欠拟合问题的模型已省略）。

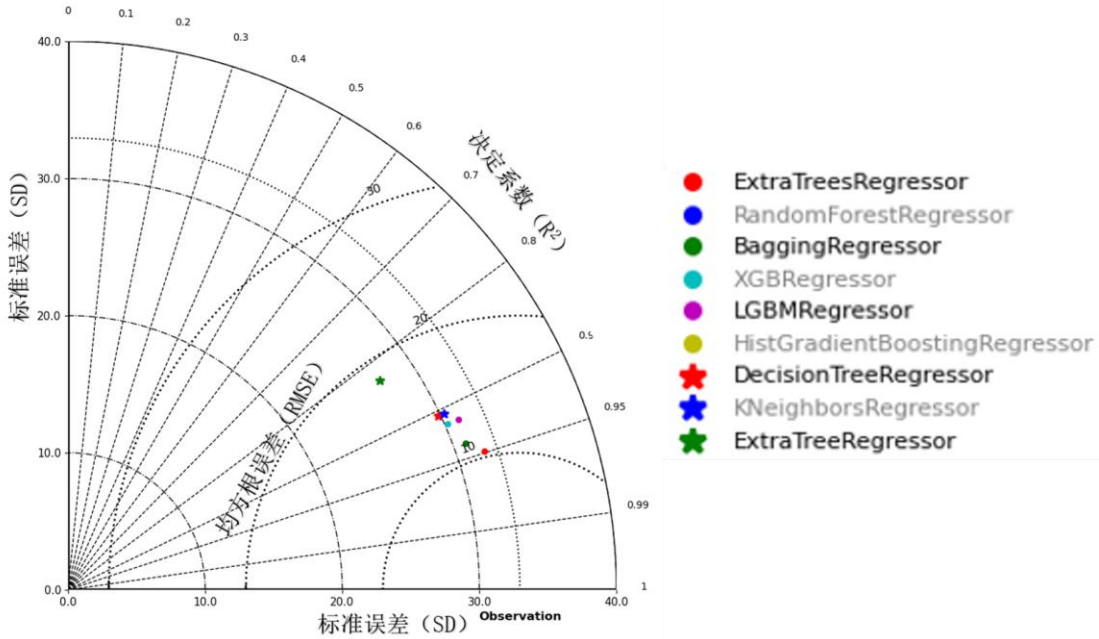



图 10 WQI-DET 预测模型泰勒图

综合全部 39 个模型的结果来看，同样是 ExtraTreesRegressor 有着最低的 RMSE 和最高的 $R^2$，相比其他模型更为稳健，在 WQI-DET 预测问题上表现最好。

应用 ExtraTreesRegressor 模型，对从 2025.05.01 后 90 天的水质做预测，设置决策树数量为 100，并对结果做 M-K 趋势检验，结果如下图：

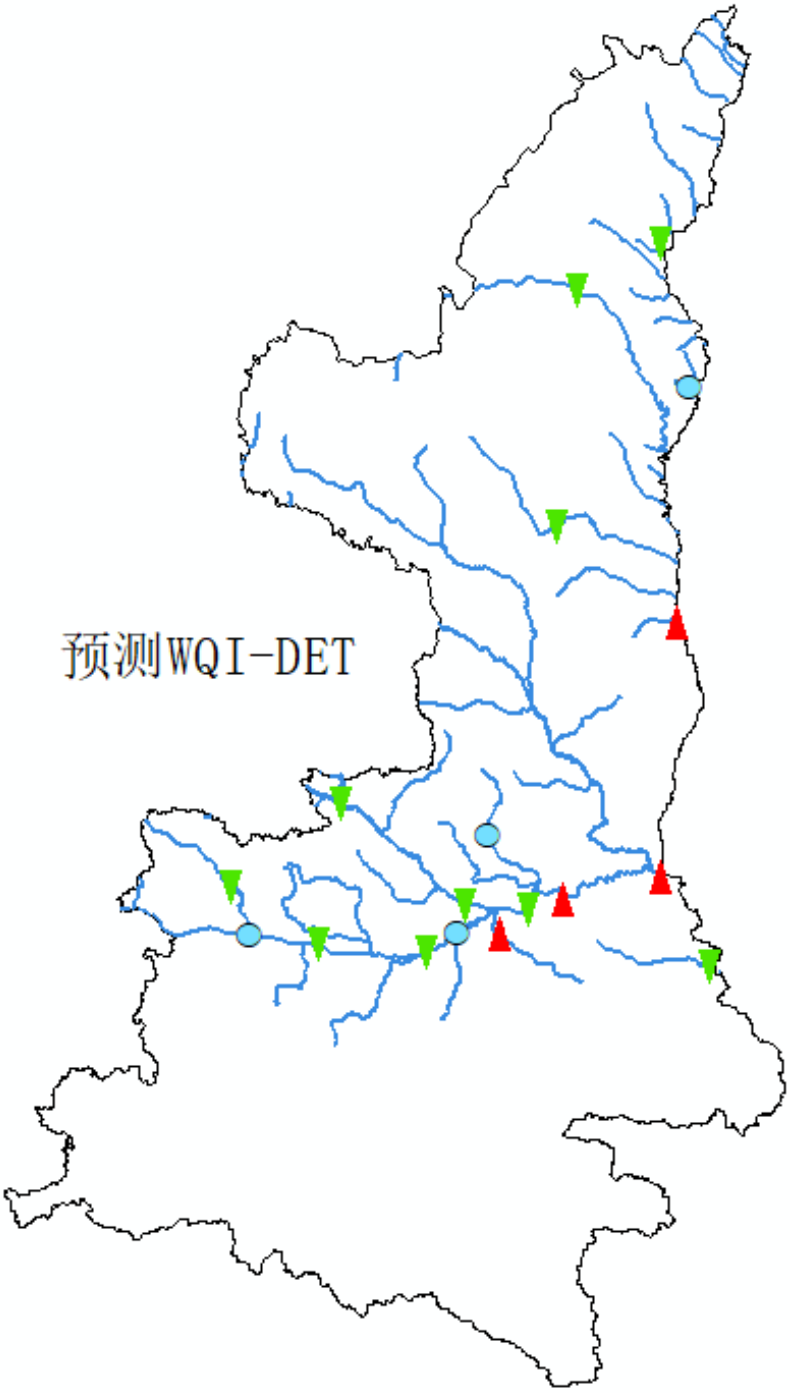



图 11 预测 WQI-DET 汛期 M-K 检验结果图

从图中可以明显看出，大部分断面水质的预测 WQI-DET 都趋于下降，与上文汛期 WQI-DET 分析有一定相似度，一定程度上体现了模型的良好性能。但下降的断面数量有所增加，为水质检测工作敲响了警钟。

# 四、结论

（1） 本研究围绕陕西省黄河流域水质展开系统分析，通过多种方法全面剖析了水质的整体和区域特征、变化趋势、污染因子以及预测模型。

（2） 在数据整体性处理及分析方面，发现水质指标不服从正态分布，各指标间存在不同程度相关性。M-K 趋势检验表明部分指标稳定，部分呈下降趋势且有周期性变化，层次聚类分析揭示了水质在空间和时间上的分布规律，与水体分布和季节密切相关。

（3） 数据区域性处理及分析显示，各水质变量变化趋势存在显著时空差异。主成分分析有效识别出不同区域和时段的主要污染因子，为针对性治理提供了科学依据，如空间聚类 1 区域应重点管控工业源污染，空间聚类 2 区域则需控制农业面源和生活污染。

（4） 在水质预测模型构建中，针对数据缺失问题构建的 WQI-DET 计算模型，经对比确定 ExtraTreesRegressor 模型性能最佳，并利用 SHAP 分析明确了各变量对 WQI-DET 的影响。该模型在 WQI-DET 预测中同样表现出色，为制定水质保护策略提供了有力支持。

总体而言，本研究在一定程度上填补了陕西省内黄河流域水质研究的空白，但仍有拓展空间。未来研究可增加监测断面和指标，延长监测时间，获取更全面数据；进一步优化机器学习模型，提升预测准确性；综合考虑流域内人类活动、气象因素等，深入揭示水质变化机制，为黄河流域水质保护和治理提供更精准有效的方案。

## 参考文献


[1] 生态环境部等.关于加强生态环境领域科技创新 推动美丽中国建设的实施意见[EB/OL].2025-02-13,https://www.gov.cn/zhengce/zhengceku/202502/content_7004695.htm.

[2] 生态环境部.关于建设美丽中国先行区的实施意见[EB/OL].2025-01-12, https://www.gov.cn/zhengce/content/202501/content_6998719.htm

[3] 徐祖信.我国河流综合水质标识指数评价方法研究 [J].同济大学学报(自然科学版)，2005，33(4) : 482-488.

[4] 徐若诗,逄勇,罗缙,等.基于 WQI 的南水北调东线江苏段水质评价及时空分布特征[J].环境科学,2024,45(9):5227-5234.Xu R S,Pang Y,Luo J,et al.Water quality evaluation and spatial-temporal distribution characteristics of the east route of the south-to-north water diversion project in Jiangsu province based on WQI[J].Environmental Science, 2024, 45 (9): 5227-5234.

[5] Huang J C, Zhang Y J, Arhonditsis G B, et al.How successful are the restoration efforts of China's lakes and reservoirs?[J]. Environment International, 2 019,123:96-103.

[6] 景朝霞，夏军，张翔，等.汉江中下游干流水质状况时空分布特征及变化规律 [J]. 环境科学研究，2019，32(1) : 104 115.

[7] 张婷，刘静玲，王雪梅.白洋淀水质时空变化及影响因子评价与分析[J].环境科学学报，2010，30(2) : 261-267.

[8] 韩晓刚，黄廷林，陈秀珍. 改进的模糊综合评价法及在给水厂原水水质评价中的应用 [J]. 环境科学学报，2013，33 (5) : 1513-1518.

[9] 向娜.基于神经网络和人工蜂群算法的水质评价和预测研究 [D] .广州: 华南理工大学，2012.

[10] Hirsch R M，Slack J R，Smith R A. Techniques of trend analysis for monthly water quality data [J]. Water Resources Research,1982,18(1) : 107-121.

[11] 刘彦龙,郑易安.黄河干流水质评价与时空变化分析[J].环境科学,2022,43(03):1332-1345.DOI:10.13227/j.hjkx.202106111.

[12] Shapiro S S, Wilk M B. An analysis of variance test for normality (complete samples) [J]. Biometrika, 1965, 52(3-4) : 591 611.